

# Métodos de Analítica II

## Support Vector Machines

Juan Eduardo Coba Puerto

Pontificia Universidad Javeriana


# Section 1

1 Fronteras de Decisión


2 La vida real...

3 Kernels Comunes

# Fronteras de Decisión



# Separación Máxima



## Section 2

1 Fronteras de Decisión

2 La vida real...

3 Kernels Comunes

# Datos No Separables




Figure: No todos los datos son linealmente separables.

# Datos No Separables Linealmente






Figure: No todos los datos son linealmente separables.

# Datos No Separables Linealmente





# Datos No Separables Linealmente



# Datos No Separables Linealmente






Figure: No todos los datos son linealmente separables.

# ¡Ahora son separables!



**Figure:** Volvimos nuestros datos linealmente separables en una dimensión más alta

# ¡Ahora son separables!



**Figure:** Volvimos nuestros datos linealmente separables en una dimensión más alta

## Section 3

1 Fronteras de Decisión


2 La vida real...

3 Kernels Comunes

# Kernel Gaussiano - RBF


$$\kappa(X, X') = e^{-gamma||X-X'||^2}$$

$$\kappa(X, X') = e^{-\frac{||X-X'||^2}{2\sigma^2}}$$



# Kernel Sigmoido

$$\kappa(X, X') = \tanh(\gamma \langle X, X' \rangle + \rho)$$



# Kernel Polinomial

$$\kappa_d(X, X') = (1 + \langle X, X' \rangle)^d$$




Figure:  $d = 2$



# Kernel Polinomial

$$\kappa_d(X, X') = (1 + \langle X, X' \rangle)^d$$




Figure:  $d = 3$