

Métodos de Analítica II

Support Vector Machines

Juan Eduardo Coba Puerto

Pontificia Universidad Javeriana


Section 1

1 Fronteras de Decisión


2 La vida real...

3 Kernels Comunes

Fronteras de Decisión



Separación Máxima



Section 2

1 Fronteras de Decisión

2 La vida real...

3 Kernels Comunes

Datos No Separables




Figure: No todos los datos son linealmente separables.

Datos No Separables Linealmente






Figure: No todos los datos son linealmente separables.

Datos No Separables Linealmente



Datos No Separables Linealmente



Datos No Separables Linealmente




Figure: No todos los datos son linealmente separables.

¡Ahora son separables!




Figure: Volvimos nuestros datos linealmente separables en una dimensión más alta

¡Ahora son separables!




Figure: Volvimos nuestros datos linealmente separables en una dimensión más alta

Section 3

1 Fronteras de Decisión


2 La vida real...

3 Kernels Comunes

Kernel Gaussiano - RBF


$$\kappa(X, X') = e^{-gamma||X-X'||^2}$$

$$\kappa(X, X') = e^{-\frac{||X-X'||^2}{2\sigma^2}}$$



Kernel Sigmoide

$$\kappa(X, X') = \tanh(\gamma \langle X, X' \rangle + b)$$



Kernel Polinomial

$$\kappa_d(X, X') = (1 + \langle X, X' \rangle)^d$$




Figure: $d = 2$

Kernel Polinomial

$$\kappa_d(X, X') = (1 + \langle X, X' \rangle)^d$$




Figure: $d = 3$